

2. naloga
Klasifikacija zvezdnih spektrov

Tadej Lozej 28242023

6. november 2025

Praktikum strojnega učenja v fiziki

Predavatelj: red. prof. dr. Borut Paul Kerševan

Asistent: doc. dr. Gregor Traven

Kazalo

1	Uvod	1
2	PCA	3
3	t-SNE	7
4	Zaključek	13
5	Dodatek	14

1 Uvod

V nalogi smo se ukvarjali s spektri zvezd v vidni svetlobi. Spekter je graf jakosti svetlobe pri določeni valovni dolžini. Envelopo spektra zvezde opišemo s Plankovim zakonom. Ta pravi, da vroča telesa sevajo več svetlobe (Štefanov zakon) ter imajo vrh spektra pri manjših valovnih dolžinah. Hladnejša telesa pa ravno obratno. V nalogi smo analizirali normalizirane spektre. To so spektri deljeni z njihovo ovojnico. Zanimale so nas predvsem spektralne črte. Iz njihove oblike namreč lahko izluščimo precej informacij o zvezdi. Na obliko spektralnih črt vpliva veliko fizikalnih procesov/lastnosti zvezde:


- **Temperatura.** Absorpcijske črte se zaradi termičnega gibanja atomov razširijo. Je glavni faktor za obliko spektralnih črt.
- **Kovinskost.** Številsko razmerje kovin (elementov težjih od helija) napram vodik, logaritmirano in normirano na vrednost za Sonce. Kovinskost vpliva na moč posameznih spektralnih črt.
- **Gravitacijski pospešek.** Vpliva na tlačno razširitev črt.
- **Radialna hitrost.** Pove nam kako hitro se zvezda giblje proti ali stran od nas. Ne vpliva na obliko spektralnih črt temveč jih premakne zaradi Dopplerjevega pojava.
- **Rotacijska hitrost.** Zaradi Dopplerjevega pojava razširi črte v polkrožni obliki.
- **Plini okrog zvezde.** Če so ti plini segreti bolj kot površje zvezde lahko sevajo močne emisijske črte.
- **Dvojne zvezde.** To so sistemi, kjer dve zvezdi krožita ena okoli druge. Zvezd je v sistemu lahko tudi več. Zaradi Dopplerjevega pojava dobimo podvajanje črt.

To je zgolj nekaj fizikalnih lastnosti zvezde, ki vplivajo na spekter zvezde. Poleg vsega tega pa moramo upoštevati še Zemljino atmosfero ter instrumentalne napake. Na sliki 1 lahko vidimo sedem različnih tipičnih primerov spektrov.

V nalogi imamo na voljo 10000 normaliziranih spektrov zvezd. Za nekaj izmed teh spektrov imamo podane fizikalne lastnosti zvezde. Efektivno temperaturo (T_{eff}), logaritem gravitacijskega pospeška ($\log g$) ter kovinskost ($[M/H]$). Za naj spektrov imamo podan tudi tip zvezde. Tipi so prikazani na sliki 1. V nalogi uporabimo kratice za tip zvezde

- MAB: zvezda z molekulskimi absorpcijskimi črtami
- BIN: dvojne zvezde
- TRI: trojne zvezde
- HFR: vroče, hitrovrteče se zvezde
- HAE: zvezde s H_{α} emisijo
- CMP: hladne zvezde z malo kovinami
- DIB: vroče zvezde z močnejšimi medzvezdnimi absorpcijami

Računsko modeliranje spektrov je zelo zahtevna naloga, zato se v praksi poslužujemo metod strojnega učenja, ki nam spektre pomagajo klasificirati. V tej nalogi si ogledamo dve klasifikacijski metodi, in sicer principal component analysis (PCA) ter t-distributed stochastic neighbor embedding (t-SNE). Obe metodi temeljita na zmanjševanju dimenzij. Vsak spekter v nalogi je opisan s 2084 spremenljivkami. Z temi metodami pa lahko spekter opišemo z recimo dvema pametno izbranimi dimenzijama, za kateri upamo, da bosta zadovoljivo ločila tipe spektrov med seboj. PCA je linearna metoda, t-SNE je pa bolj napredna nelinearna metoda.




Slika 1: Na sliki je prikazanih 7 normaliziranih spektrov, ki pripadajo različnim tipom zvezd (naslov grafa).

2 PCA

Metoda glavnih komponent je ena od osnovnih metod zmanjševanja dimenzij. Je linearna metoda. S to metodo naredimo dekompozicijo našega podatkovnega seta v lastne vektorje in lastne vrednosti. Dimenzije dobljenih lastnih vektorjev so linearna kombinacija vhodnih dimenzij. Lastne vektorje lahko sortiramo od najbolj do najmanj pomembnih po njihovih lastnih vrednostih, ki podajajo varianco podatkov v večdimenzionalnem prostoru. Cilj PCA je poiskati nekaj prvih lastnih vektorjev, ki najbolje opišejo večji del razpršenosti podatkovnega seta. Moja implementacija PCA-ja se nahaja v razdelku Dodatek.

Za začetek si na sliki 2 oglejmo normalizirano kumulativno vsoto lastnih vrednosti (modra) ter lastne vrednosti glavnih komponent (rdeča) v logaritemski skali. Vidimo, da je naša PCA metoda našla 2084 novih koordinat, ki jih opisujejo lastni vektorji in jih zložila po padajoči lastni vrednosti. Z nekaj prvimi koordinatami lahko zajamemo večino informacije oz. variance našega podatkovnega seta. Odličimo se za ohranitev 90% variance. V tem primeru vsak spekter opišemo zgolj z 101 koordinatami. Na grafu lahko vidimo tudi da le prve tri glavne komponente opišejo več kot 70% raztrešenosti.




Slika 2: Na grafu je prikazana normirana kumulativna vsota lastnih vrednosti (modra) ter lastne vrednosti (rdeča), ki jih dobimo z danim setom podatkov ter PCA metodo. Devetdeset odstotkov variance dosežemo že z zgolj 101 PCA koordinatami.

Dvodimenzionalna porazdelitev spektrov s prvimi tremi glavnimi koordinatami je prikazana na sliki 3. Na x in y oseh so prve tri glavne koordinate PCA metode označene z PCA_i . Diagonalni grafi so zgolj histogrami, ki prikazujejo porazdelitev spektrov po glavnih koordinatah. Izvendiagonalni grafi pa prikazujejo dvodimenzionalne porazdelitve po dveh glavnih komponentah.

Na spodnji diagonali lahko vidimo z zvezdicami različnih barv narisane spektre znanega tipa. Vidimo, da metoda ne deluje tako slabo. Vidimo, da so si DIB zvezde precej blizu v vseh porazdelitvah. Enako lahko rečemo za TRI in BIN zvezde. Se pa te dve skupini držita precej skupaj. CMP zvezde se prav tako držijo precej skupaj. Tudi HFR zvezde niso preveč raztrešene. Zelo presenetljivo so precej raztrešene zvezde z H_α emisijo (HAE). Tega nisem pričakoval, saj imajo precej unikatno značilnost. Zvezde z molekulskimi absorpcijskimi črtami (MAB) so prav tako precej raztrešene v naši porazdelitvi. Zadnja dva rezultata sta me presenetila, saj sta to na videz najbolj očitni lastnosti spektra teh zvezd. Mogoče pa zvezde teh tipov tvorijo več skupkov vendar jih z tako malo znanimi spektri težko ločimo. Kot kaže glavne tri komponente PCA metode precej dobro klasificirajo spektre glede na obliko spektralnih črt.

Na zgornji diagonali lahko vidimo z barvnim gradientom prikazane znane efektivne temperature zvezd. Te so prikazane tudi na histogramskih porazdelitvah. Vidimo lahko, da prva PCA koordinata zelo dobro razvrsti zvezde glede na njihovo efektivno temperaturo.




Slika 3: Diagonalni grafi prikazujejo porazdelitev spektrov po prvih treh glavnih PCA koordinatah. Izvendiagonalni grafi prikazujejo dvodimenzionalne porazdelitve spektrov po dveh izmed prvih treh glavnih PCA koordinatah. Na spodnji diagonalni so z zvezdami različnih barv prikazani tudi različni tipi spektrov. Na zgornji diagonalni ter spodnjem delu histogramov so z barvnim gradientom prikazane znane efektivne temperature zvezd.

Slika 4 je pravzaprav nadaljevanje analize iz prejšnje slike a za drugi dve pomembni fizikalni lastnosti. Enako kot prej vidimo na diagonalnih grafi histograme ter na izvendiagonalnih grafi dvodimenzionalne porazdelitve po prvih treh glavnih PCA koordinatah.

Na spodnji diagonalni so z barvnim gradientom poudarjeni znani gravitacijski pospeški zvezd. Prav tako so prikazani tudi na spodnjem delu histogramov. Spet vidimo, da prva glavna PCA koordinata zelo dobro loči spektre glede na gravitacijski pospešek zvezde. Druga in tretja koordinata ne tako dobro.

Na zgornji diagonalni ter na zgornjem delu histogramov lahko z barvnim gradientom vidimo znane vrednosti kovinskosti zvezd. Na prvi pogled nobena izmed prvih treh koordinat ne dobro razloči kovinskosti med seboj.

Med to očesno analizo sem razmišljal o bolj kvantitativnem načinu o tem kako posamezne koordinate dobro opišejo tri omenjene fizikalne količine. Spomnil sem se na preprosti korelacijski koeficient. Na sliki 5 lahko vidimo porazdelitev spektrov po treh pomembnih fizikalnih količinah ter prvih treh glavnih PCA koordinat. V okvirčku lahko vidimo tudi izračunano Pearsonovo (r) ter Spearmanovo (ρ_s) korelacijo. Ker




Slika 4: Diagonalni grafi prikazujejo porazdelitev spektrov po prvih treh glavnih PCA koordinatah. Izven-diagonalni grafi prikazujejo dvodimenzionalne porazdelitve spektrov po dveh izmed prvih treh glavnih PCA koordinatah. Na spodnji diagonalni ter spodnjem delu histogramov so z barvnim gradientom prikazane znani gravitacijski pospeški zvezd. Na zgornji diagonalni ter zgornjem delu histogramov so z barvnim gradientom prikazane znane kovinskosti zvezd.


se osredotočano na kategorizacijo spektrov predznak korelacije ni pomemben. Rezultat kaže skoraj popolno korelacijo med temperaturo ter prvo glavno PCA koordinato.. Kaže tudi precej dobre korelacije med gravitacijskim pospeškom zvezde ter prvo ter drugo glavno PCA koordinato ter temperaturo ter tretjo glavno PCA koordinato. Kovinskost ima največjo korelacijo s tretjo glavno PCA koordinato.

V upanju, da najdemo boljšo koordinato za opis kovinskosti izračunajmo korelacijo med fizikalnimi količinami ter več PCA koordinatami. Na sliki 6 lahko vidimo izračunano absolutno Pearsonovo ter Spearmanovo korelacijo med tremi pomembnimi fizikalnimi količinami ter prvimi 101 glavnimi PCA koordinatami. Vidimo, da so korelacije med temperaturo ter prvimi tremi PCA koordinatami največje. Gravitacijski pospešek ima največje korelacije s prvima dvema PCA koordinatama. Tudi v poznejših koordinatah vidimo par večjih korelacij. Kovinskost ima pa največjo korelacijo z sedmo PCA koordinato. Z nobeno koordinato nima tako velike korelacije kot jih imata temperatura ter gravitacijski pospešek.

Korelacije prvih treh poglavitvenih vrednosti PCA metode z pomembnimi fizikalnimi količinami




Slika 5: Porazdelitev spektrov v odvisnosti od treh pomembnih fizikalnih količin ter treh glavnih PCA koordinat. V okvirčkih sta izračunana Pearsonova ter Spearmanova korelacija.



Slika 6: Pearsonov in Spearmanov korelacijski koeficient med tremi pomembnimi fizikalnimi količinami ter 101 glavnimi PCA koordinatami.

S tem novim znanejem narišimo še dvodimenzionalno porazdelitev spektrov v odvisnosti od tretje ter sedme PCA koordinate. To lahko vidimo na grafu zgoraj desno na sliki 7. Opazimo tudi precej manjšo varianco sedme koordinate. Opazimo nek trend naraščajoče kovinskosti vendar niti približno ne tako dober kot s temperaturo ali gravitacijskim pospeškom. Na diagonalnih grafih lahko vidimo porazdelitev spektrov le po tretji ter sedmi koordinati. Na grafu levo spodaj lahko vidimo porazdelitev spektrov po kovinskosti ter sedmi PCA koordinati. V okvirčku vidimo tudi izračunana korelacijska koeficienta.



Slika 7: Diagonalna grafa prikazujeta porazdelitev spektrov po tretji ter sedmi PCA koordinati. Zgoraj desno je prikazana dvodimenzionalna porazdelitev spektrov po tretji ter sedmi PCA koordinati. Spodaj levo je prikazana porazdelitev spektrov po kovinskosti ter sedmi PCA koordinati. V okvirčku sta podana tudi Pearsonov ter Spearmanov korelacijski koeficient.

3 t-SNE

Metoda t-SNE je nelinearna metoda za reduciranje dimenzij. Temelji na ideji o ohranitvi lokalnih odnosov med točkami. Točke, ki so si v izvornih podatkih blizu naj si bojo blizu tudi v nizkodimenzionalni predstavitvi.

Postopek najprej v visoko dimenzionalnem prostoru izračuna podobnost oz. verjetnost podobnosti med točkami na osnovi izbrane metrike razdalje. Ponavadi uporabimo kar evklidsko metriko vendar se lahko

poslužimo tudi drugih metrik. Izbira metrike ima precej ključno vlogo, saj določa kaj pomeni bližina med točkami v originalnem prostoru.

Parameter perplexity v metodi t-SNE v grobem določa koliko sosedov naj posamezna točka v podatkovnem prostoru upošteva pri gradnji lokalnih verjetnostnih porazdelitev. Lahko si ga predstavljamo kot število sosedov, ki vplivajo na to, kako se točka razporedi v nizkodimenzijskem prostoru.

Na sliki 8 lahko vidimo porazdelitev spektrov v dvodimenzijskem t-SNE prostoru ob uporabi evklidske metrike za nekaj različnih vrednosti parametra perplexity. V porazdelitvi z zvezdicami različnih barv prav tako vidimo spektre znanih tipov. Vidimo, da se pri majhnih vrednostih parametra perplexity tvori precej očitnih skupkov v prostoru. Spektri znanih tipov so si precej blizu eden drugemu. Pri srednjih vrednostih parametra skupki postanejo večji in jih je posledično tudi manj. Pri velikih vrednostih parametra perplexity vidimo, da se prej lepo definirani skupki začnejo združevati. Na videz sta najboljše vrednosti parametra 20 in 30. Zvezde tipa BIN so raztresene po večjem delu porazdelitve. Zvezde tipa MAB ter CMP pa tvorijo več skupkov.

Poleg evklidske metrike za uporabo t-SNE sem si ogledal tudi projekcije z uporabo treh drugih metrik. Smiselne sta se mi zdele kosinusna 9 ter korelacijska 10 metrika. Te dve ne upoštevata amplitud absorpcijskih in emisijskih črt temveč zgolj obliko spektra. Uporabil sem tudi cityblock oz. Manhattan metriko 11. Izbral sem jo, ker ta metrika velika ter majhna odstopanja koordinat upošteva enako, medtem ko evklidska metrika velika odstopanja posameznih koordinat bolj penalizira. Če ima spekter na enakem mestu različno globoke absorpcijske črte cityblock metrika različne globine penalizira manj kot evklidska metrika.


Pri kosinusni metriki 9 in naraščanju perplexitija lahko vidimo podbne pojave. Sama porazdelitev spektrov po prostoru je precej podobna kot pri evklidski metriki. Pojavijo se podobni skupki, ki so mogoče le drugače zarotirani in pozicionirani v prostoru. Se mi pa zgolj na pogled vseeno zdi, da je pri evklidski metriki ločitev boljša.

Pri korelacijski metriki 10 je porazdelitev rahlo drugačna kot prejšnjih dveh primerih. Nastalo je nekaj skupkov vendar ne toliko kot v primeru evklidske metrike.

Cityblock oz. Manhattan metrika 11 vrne podobno porazdelitev kot evklidska metrika. Razlike so praktično minimalne.


Na sliki 12 lahko še enkrat vidimo porazdelitev v t-SNE projekciji z evklidsko metriko in parametrom perplexity 30. Z rdečo je označeno jasno ločen skupek spektrov v katerem se ni nahajal nobeden izmed spektrov znanega tipa. Iz tega razloga sem si izbral to območje ter narisal povprečni spekter devetdesetih spektrov v tem območju. Vidimo močno absorpcijo pri valovni dolžini H_{α} ter kar precej absorpcije pri drugih valovnih dolžinah. Nisem astronom ampak sklepam, da gre za skupino hladnih zvezd z veliko kovinami.

Porazdelitev spektrov po dveh t-SNE koordinatah za različne vrednosti parametra perplexity




Slika 8: Porazdelitev spektrov v 2D t-SNE prostoru pri različnih vrednostih parametra perplexity ter uporabi evklidske metrike.

Porazdelitev spektrov po dveh t-SNE koordinatah za različne vrednosti parametra perplexity




Slika 9: Porazdelitev spektrov v 2D t-SNE prostoru pri različnih vrednostih parametra perplexity ter uporabi kosinusne metrike.

Porazdelitev spektrov po dveh t-SNE koordinatah za različne vrednosti parametra perplexity




Slika 10: Porazdelitev spektrov v 2D t-SNE prostoru pri različnih vrednostih parametra perplexity ter uporabi **Korelacijske metrike**.

Porazdelitev spektrov po dveh t-SNE koordinatah za različne vrednosti parametra perplexity



Slika 11: Porazdelitev spektrov v 2D t-SNE prostoru pri različnih vrednostih parametra perplexity ter uporabi Manhattan metrike.



Slika 12: Porazdelitev spektrov v 2D t-SNE prostoru vrednosti parametra perplexity 30 ter uporabi **Evklidske metrike**. Z rdečo je označen skupek spektrov. Spodaj je prikazan povprečen spekter izbranega območja skupaj z standardnim odklonom.

4 Zaključek

V nalogi smo klasificirali zvezdne spektre s pomočjo linearne metode PCA ter nelinearne metode t-SNE. Glavna ideja je projekcija spektrov iz velikodimenzionalnega prostora v smiselno manjdimenzionalen prostor. Pri prvi metodi sem si ogledal različne porazdelitve ter izračunal korelacije med glavnimi koordinatami ter določenimi fizikalnimi količinami. Pri drugi metodi sem si ogledal porazdelitve z uporabo različnih metrik ter različnih vrednostih perplexity. V porazdelitvi sem si izbral izoliran skupek spektrov ter narisal povprečen spekter tega skupka. Mislim, da gre za hladne zvezde z veliko kovinami.

5 Dodatek

```
def PCA(X, eta):
    u = X.mean(axis=0) # Povprečja stolpcev
    B = X - u # Centriranje
    C = 1 / (n-1) * B.T @ B
    eigvals, eigvecs = np.linalg.eigh(C) # Lastni razcep

    # sortiramo po padajoči vrednosti (večja varianca prva)
    idx = np.argsort(eigvals)[::-1]
    eigvals = eigvals[idx] # (p,) padajoče
    V = eigvecs[:, idx] # (p, p) stolpci = lastni vektorji

    # kumulativna energija in delež
    cum_energy = np.cumsum(eigvals) # g_j
    total_energy = cum_energy[-1] # G
    frac = cum_energy / total_energy # frakcija razložene variance do j-te komponente

    # najdi najmanjše q za dano mejo eta
    q = int(np.searchsorted(frac, eta) + 1) # +1, ker indeksi začnejo pri 0, j pa pri 1

    print(f"Za {eta*100:.1f}% energije potrebujemo q = {q} komponent.")

    # Redukcija dimenzij
    W = V[:, :q]
    T = X @ W

    return T, eigvals, frac
```

Slika 13: Python funkcija, ki izvede PCA.