

3. naloga

Določanje elastičnih konstant v nematskem tekočem kristalu

Tadej Lozej 28242023

20. november 2025

Praktikum strojnega učenja v fiziki

Predavatelj: red. prof. dr. Borut Paul Kerševan

Asistent: Jaka Zaplotnik

Kazalo

1	Uvod	1
2	Podatki	2
3	Uporaba nevronske mreže	3
3.1	Nezašumljeni podatki	4
3.2	Zašumljeni podatki	7
3.3	Dve elastični konstanti	7
3.4	Eksperimentalni podatki	9
4	Zaključek	12

1 Uvod

Elastične konstante so pomembna lastnost tekočih kristalov. V tej nalogi bomo spoznali potencialen nov način za določitev le-teh v nematskem tekočem kristalu. To bomo storili s pomočjo nevronske mreže.

V nemarskem tekočem kristalu orientacijski red opišemo z direktorskim poljem $\vec{n}(\vec{r})$. Ta v vsaki točki kaže v smeri lokalne ureditve gradnikov. Direktor je vektor brez glave. To pomeni, da sta smeri $\vec{n}$ ter $-\vec{n}$ ekvivalentni. Harmonično teorijo tekočih nematskih tekočih kristalov začnemo opisovati z Frank-Oseenovo gostoto elastične proste energije.

$$f_{elastic} = \frac{1}{2}K_{11}(\nabla \cdot \vec{n})^2 + \frac{1}{2}K_{22}(\vec{n} \cdot \nabla \times \vec{n})^2 + \frac{1}{2}K_{33}(\vec{n} \times \nabla \vec{n})^2, \quad (1)$$

kjer so K_{11} , K_{22} in K_{33} različne deformacijske konstante. Prvi člen predstavlja pahljačasto deformacijo, drugi zvojno in tretji upogibno.

Eksperimentalno določanje deformacijskih konstant izkorišča odziv tekočega kristala na zunanje električno polje. Konceptualno je preprost ampak eksperimentalno še zdaleč ni trivialen, saj je težko natančno kontrolirati eksperimentalne pogoje in posledično rezultati v literaturi močno variirajo.

Obstaja povezava med elastičnostjo tekočih kristalov ter njihovimi optičnimi lastnostmi. Ureditvena anizotropija povzroči dvolomnost. Svetlobni žarek, ki potuje skozi tekoči kristal lahko razdelimo na redno in izredno komponento. Potovanje rednega žarka ni odvisno od smeri direktorja. Propagacija izrednega žarka pa je odvisna od kota θ med ravnino, pravokotno na valovni vektor $\vec{k}$, ter direktorjem $\vec{n}$.

Če direktor v smeri osi z spreminja svojo smer je posledično za izredni žarek lomni količnik $n = n(z)$. Posledično dobimo fazni zamik med rednim ter izrednim žarkom, ki je odvisen od profila lomnega količnika. Razlika v fazi je

$$\Gamma = \frac{2\pi}{\lambda} \int_0^d (n(z) - n_0) dz, \quad (2)$$

kjer je d debelina vzorca, λ valovna dolžina svetlobe ter n_0 lomni količnik za redni žarek. Če je začetni profil lomnega količnika ustreza neravnovesnemu stanju tekočega kristala se ta relaksira z nekimi karakterističnimi časi, ki so odvisni od elastičnih konstant. Iz časovne evolucije profila lomnega količnika bi lahko na nek način pridobili elastične konstante.

V nalogi obravnavamo enostaven model nematskega tekočega kristala med dvema neskončnima plosčama z dvodimenzionalnim direktorskim poljem

$$\vec{n}(z) = (\cos \theta(z), 0, \sin \theta(z)). \quad (3)$$

Z izbiro sidranja izberemo $\theta(0)$ ter $\theta(d)$. Izraz za gostoto elastične proste energije se poenostavi v

$$f_{elastic} = \frac{1}{2}K_{11} \left(\frac{\partial n_z}{\partial z} \right)^2 + \frac{1}{2}K_{33} \left(\frac{\partial n_x}{\partial z} \right)^2. \quad (4)$$

Zanima nas relaksacija direktorskega polja iz nekega začetnega profila $\theta(z, t = 0)$ v ravnovesno stanje $\theta(z, t = \infty)$. To določimo z reševanjem Euler-Lagrangeove enačbe. Dobimo difuzijsko enačbo za relaksacijo $\theta(z, t)$, ki vsebuje obe elastični konstanti.


Funkcije $\theta(z)$ nemoremo eksperimentalno izmeriti. Izmerimo pa lahko intenziteto prepuščene svetlobe skozi vzorec. Pred in za vzorec tekočega kristala postavimo polarizator ($\pi/4$) ter analizator ($-\pi/4$). Časovno spreminjanje intenzitete nam da podatek o relaksaciji direktorskega polja, ki je pogojena z elastičnimi konstantami.

Cilj naloge je pokazati, da lahko z dobro naučeno nevronske mreže zgolj iz podatka o spreminjanju intenzitete $I(t)$ zanesljivo ter natančno določimo elastične konstante nematskega tekočega kristala.


2 Podatki

Na voljo imamo 100000 simulacij. Za vsako simulacijo imamo podan začetni profil orientacije direktirja, vrednost elastične konstante ($K_{11} = K_{22} = K$ v prvem delu naloge sta enaki), intenzitetni profil ter zašumljen intenzitetni profil. Intenzitetni profili so podani za štiri različne vrednosti valovnih dolžin $\lambda = 500, 505, 700, 900$ nm.

Na sliki 1 lahko vidimo histogram vrednosti elastične konstante K prisotne v simulacijah. Minimalna vrednost je $2 \cdot 10^{-18}$ maksimalna pa $2 \cdot 10^{-11}$. Med tema dvema vrednostima so konstante uporabljene v simulaciji precej enakomerno porazdeljene.




Slika 1: Porazdelitev vrednosti elastične konstante K uporabljenih v simulacijah.



Slika 2: Profili intenzitete, ki najbolj odstopajo od povprečnega profila.

Na sliki 2 lahko zgoraj vidimo tri profile intenzitete, ki najbolj odstopajo od povprečnega profila intenzitete, ki je prikazan v vrinjenem grafu s črno črto. Vsi tri profili so skoraj konstantni. Prav tako imajo vsi tri profili majhne elastične konstante. Te dve lastnosti sta najverjetneje povezani. Majhna elastična konstanta je kriva za počasno relaksacijo. Manjša kot je elastična konstanta počasnejša je relaksacija. Na spodnjem delu slike so prikazani tudi začetni profili orientacije direktorja za vse tri primere.

Našo hipotezo o povezavi velikosti elastične konstante ter času relaksacije lahko vizualno preverimo na sliki 3. Na sliki vidimo pet primerov relaksacije začetnega profila na levi ter ustrezne intenzitete v odvisnosti od časa za vse valovne dolžine na desni. Od zgoraj navzdol vrednost elastične konstante narašča. Vidimo, da se na prvi pogled relaksacijski čas krajša. Pri primeru z najmanjšo elastično konstanto se profil praktično sploh ne spremeni. Pri primeru z največjo elastično konstanto se pa profil relaksira zelo hitro.



Slika 3: Profili intenzitete, ki najbolj odstopajo od povprečnega profila.


3 Uporaba nevronske mreže

Želimo skonstruirati nevronske mreže, ki bi za vsak časovni potek intenzitete $I(t)$ znala določiti elastično konstanto K . Vhodni podatek mreže je vektor $\vec{X} = [I_{t=0}, I_{t=\Delta t}, \dots, I_{t=399\Delta t}]$ izhodni pa $\vec{Y} = [K]$. Eksperimentalno zadostne količine podatkov za učenje nevronske mreže nemoremo doseči, zato se poslužujemo simulacij.

Za vse ocene uspešnosti modelov sem uporabil navskrižno KFold validacijo. Ta avtomatsko razdeli podatke na dva dela. Enemu delu recimo X drugemu pa X_{test} . Podatke X med treningom nadalje razdelimo na del za treniranje X_{train} ter del za validacijo X_{val} . S podatki X_{train} optimiziramo parametre mreže, s


podatki X_{val} pa učenje pravočasno ustavimo, da ne pride do prekomernega prilagajanja. To storimo s pomočjo stoploss callbacka, ki ga keras omogoča. Na tretji neodvisna množica podatkov X_{test} pa določimo uspešnost mreže.

3.1 Nezašumljeni podatki



Slika 4: Povprečne funkcije izgube mreže z dvema skritima slojema v odvisnosti od števila Epochov za različne aktivacijske funkcije nevronov. Prikazani sta trening ter validacijska funkcija izgube. Prav tako je prikazana povprečna MAE vrednost med testno množico in napovedjo. Uporabljeni so zgolj podatki intenzitete pri $\lambda = 500 \text{ nm}$.

Nezašumljene podatke sem uporabil zato, da bi dobil optimalne hiperparametre mreže. Na začetku sem za učenje uporabil zgolj podatke pridobljene iz $I(\lambda = 500 \text{ nm})$. Rezultati za učenje mreže z dvema skritima slojema ob uporabi različnih aktivacijskih funkcij so prikazani na sliki 4. Prva skrita plast ima dvesto nevronov, druga pa sto. Na grafih so prikazane funkcije izgube (Loss funkcije) trening ter validacijske množice, ki so v resnici zgolj MAE metrika. S črtkano črto je prikazana tudi MAE vrednost med




Slika 5: Povprečne funkcije izgube nevronske mreže različnih geometrij. Na sliki so prikazane povprečne funkcije izgube trening ter validacijske množice. S črtkano zeleno črto je prikazana povprečna vrednost MAE med napovedjo ter testno množico. V okvirčku sta zapisana MAE ter MSE med napovedjo ter testno množico.

napovedjo najboljše mreže ter testno množico podatkov. V okvirčku sta zapisana MAE in MSE odstopanja testne množice od napovedi. Vidimo, da je najslabša aktivacijska funkcija za ta primer linearna funkcija. Povprečni test MAE je namreč precej večji kot pri vseh ostalih aktivacijskih funkcijah. Izgleda kot da je sigmoid na tretjem mestu. Tangens hiperbolicus in relu pa sta si precej blizu po uspešnosti. Izgleda, kot da se je mreža z aktivacijsko funkcijo tanh natrenirala v malo manj epochih kot mreža z relu ampak je mreža z relu useeno uspešnejša. Iz tega razloga bomo nadaljevali z aktivacijsko funkcijo relu.

Za nadalnje učenje mrež sem za vhodne podatke uporabil vse porfile intenzitet. Zato sem mogel umetno podaljšati izhodni vektor elastičnih konstant sam s seboj. Nevronska mreža se je tudi na takšnih podatkih uspešno učila. Na sliki 5 lahko vidimo treniranje več različnih geometrij nevronske mreže. Na vsakem grafu lahko vidimo funkcijo izgube trening ter validacijske množice, Prav tako s črtno črto vidimo MAE med napovedjo najboljše mreže ter testno množico. V okvirčku sta zapisani obe MAE ter MSE vrednost odstopanja. Na sliki so prikazana učenja štirih različnih mrež. Prva mreža ima le eno skrito plast z 200 nevroni. Vidimo, da se je mreža uspešno učila. Najboljši rezultati so z mrežo, ki ima tri skrite plasti, in sicer z 200, 100 ter 50 nevroni.


Najbolj pomembna je učinkovitost modela na še nevidenih podatkih. Prej sem omenil, da KFold validacija podatke razdeli na tri množice. Ampak v KFold validacijo sem dal le 90% vseh podatkov. Preostalih 10% podatkov poimenujmo $\tilde{X}_{test}$ ter $\tilde{Y}_{test}$. To je 40000 simulacij, ki jih nobena od nevronske mreže ni videla. S to množico podatkov lahko testiramo kako dobre so napovedi najboljšega modela. Od zdaj naprej bom testiral model s tremi skritimi sloji ter aktivacijsko funkcijo relu. Na sliki 6 lahko vidimo primerjavo napovedanih ter pravih vrednosti K/K_{max} . Z rdečima ter zelenima črtnima črtama lahko vidimo območja v katerih se nahajajo napovedi z 5% in 10% napako. Znotraj rdečega območja se nahaja 71% napovedi, znotraj zelenega pa 82% napovedi.



Slika 6: Primerjava Napovedanih ter pravih vrednosti. Z rdečo ter zeleno črtno črto sta podani območji za 5% ter 10% napako.

3.2 Zašumljeni podatki

Poleg nezašumljenih podatkov imamo podane tudi z belim šumom zašumljene podatke. Če mrežo naučimo na zašumljenih podatkih bomo mogoče dobili bolj robusten model. Na sliki 7 lahko vidimo funkcije izgube KFold učenja nevronske mreže s tremi skritimi sloji naučeno na podatkih brez šuma (zgoraj) ter na podatkih s šumom (spodaj). Vidimo, da je funkcija izgube dosegla nižjo vrednost na mreži učeni brez šuma. Tukaj je potrebno poudariti, da se je mreža validirala ter testirala na enakem tipu podatkov kot na katerih se je učila (zašumljeni/nezašumljeni). Eksperimentalni podatki so zmeraj zašumljeni in mreža, ki je naučena na nezašumljenih podatkih teh v resnici nikoli ni videla.




Slika 7: Povprečne funkcije izgube nevronske mreže, ki smo jo učili na zašumljenih ter nezašumljenih podatkih. Prikazani sta funkcija izgube validacijske množice ter trening množice. Prav tako je s črtkano zeleno črto prikazano MAE odstopanje med napovedjo mreže ter testnimi podatki.

Obe modela se splača testirati na zašumljenih ter nezašumljenih podatkih. Ti rezultati so prikazani na sliki 8. V naslovih model0 označuje model, ki je bil naučen na nezašumljenih podatkih, model100 pa model, ki je bil naučen na zašumljenih podatkih. Na zgornjih dveh slikah vidimo kako dobro modela napovesta elastične konstante na nezašumljenih podatkih. Vidimo, da se tukaj model0 bolje odreže. A precej važno je kako dobro modela napovesta elastične konstante iz zašumljenih podatkov. To lahko vidimo na spodnjih dveh grafih. Vidimo, da na tem tipu podatkov model100 bolje napove elastične konstante. V tem smislu lahko rečemo, da je bolj robusten kot model0.

3.3 Dve elastični konstanti

Tekoči kristali imajo v splošnem različno velike elastične konstante. V tem podpoglavju si oglejmo učenje mreže na podatkih, ki upoštevajo dve različni elastični konstanti K_{11} ter K_{33} . Na sliki 9 lahko vidimo funkcijo izgube ob učenju mreže na nezašumljenih podatkih z dvema elastičnima konstantama in različnimi sidranji (planarno-planarno, planarno-homeotropno, homeotropno-homeotropno). Vidimo, da se je mreža uspešno naučila na vseh množicah podatkov. Povprečni MAE med testnimi podatki ter napovedjo najboljše mreže so večji kot prej, ker mreža sedaj napoveduje dve vrednosti in ne samo ene. Najuspešnejše je testne podatke mreža napovedala na hh načinu sidranja.

Na sliki 10 lahko vidimo funkcije izgube ob učenju mreže na zašumljenih podatkih. Lahko vidimo, da so MAE odstopanja med napovedjo ter dejanskimi vrednostmi večja kot pri nezašumljenih podatkih ampak to




Slika 8: Primerjava napovedanih ter pravih vrednosti elastičnih konstant modela0 (model natreniran na nezašumljenih podatkih) ter modela100 (model natreniran na zašumljenih podatkih). Vidimo, da model0 bolje napove elastične konstante iz nezašumljenih podatkov a slabše iz zašumljenih. V tem smislu lahko rečemo, da je model100 bolj robusten.

je seveda smiselno, saj so testni podatki prav tako zašumljeni.

Na sliki 11 lahko vidimo kako dobre so napovedi modelov na testnih podatkih. Na x osi vidimo šest različnih modelov. Model0-ij je model, ki je bil naučen na nezašumljenih podatkih z tipom sidranja ij. Model100-ij je model, ki je bil naučen na zašumljenih podatkih s tipom sidranja ij. Z modro lahko vidimo histogramiran delež vrednosti konstant K_{11} , ki jih je model napovedal z 5% napako. Brez šrafure je model napovedal konstanto iz nezašumljenih podatkov s šrafuro pa iz zašumljenih. Enako smo z oranžno sliko histogramirali delež uspešnih napovedi konstante K_{33} .

Vidimo, da v splošnem hh modeli bolje napovedujejo K_{33} konstanto kot K_{11} konstanto. Izgleda, da v tem načinu sidranja upogibna deformacija igra ključno vlogo pri urejanju direktorja. Obratno lahko rečemo za pp sidranje. V teh primerih lahko rečemo, da bolje napovemo K_{11} konstanto. Izgleda kot, da pri tem načinu sidranja pahljačasta deformacija igra glavno vlogo pri urejanju direktorja. Za ph sidranje obe konstanti napovemo približno enako natančno.

Učenje nevronske mreže na podatkih z različnim sidranjem



Slika 9: Povprečne funkcije izgube nevronske mreže, ki smo jo učili na podatkih z dvema elastičnima konstantama in različnimi sidranji. Prikazani sta funkcija izgube validacijske množice ter trening množice. Prav tako je s črtkano zeleno črto prikazano MAE odstopanje med napovedjo mreže ter testnimi podatki.


Opazimo lahko tudi razliko med modeli, ki so naučeni na zašumljenih in nezašumljenih podatkih. Vidimo lahko, da modeli, ki so naučeni na nezašumljenih podatkih bolje napovejo elastične konstante iz nezašumljenih podatkov kot zašumljenih. Te konstante napovejo boljše kot modeli, ki so naučeni na zašumljenih podatkih. A kot smo že omenili je robustnost mreže pomembna, saj so praktično vsi eksperimentalni podatki zašumljeni. Za bolj robustne se izkažejo modeli, ki so naučeni na zašumljenih podatkih. Ti modeli boljše napovejo elastične konstante iz zašumljenih podatkov.

3.4 Eksperimentalni podatki


K nalogi so bili priloženi tudi eksperimentalni podatki. Ti imajo oh način sidranja. Za napovedovanje elastičnih konstant lahko uporabimo model0-ph ter model100-ph. Na sliki 12 lahko vidimo histogram napovedi elastičnih konstant K_{11} ter K_{33} . Prav tako lahko vidimo povprečja porazdelitev ter z rdečo črto realne vrednosti konstant. Vidimo, da sta naša modela napovedala premajhne vrednosti. To je najverjetneje zaradi fizikalnih procesov, ki so med eksperimentom prisotni a v simulaciji niso. Kljub temu je model100 boljši.

Na sliki 13 lahko vidimo porazdelitev napovedi petih modelov obeh tipov. Znatno se je premaknilo le eno povprečje od štirih. Na srečo proti realni vrednosti elastične konstante. Vseeno so skoraj vse napovedane vrednosti prenizke.


Učenje nevronske mreže na zašumljenih podatkih z različnim sidranjem




Slika 10: Povprečne funkcije izgube nevronske mreže, ki smo jo učili na podatkih z dvema elastičnima konstantama in različnimi sidranji. Prikazani sta funkcija izgube validacijske množice ter trening množice. Prav tako je s črtkano zeleno črto prikazano MAE odstopanje med napovedjo mreže ter testnimi podatki.



Slika 11: Delež napovedi elastičnih konstant znotraj 5% napake. Prikazane so natančnosti napovedi šestih različnih modelov. Model0-ij so modeli, ki smo jih naučili na nezašumljenih podatkih z ij sidranjem. Model100-ij so modeli, ki smo jih naučili na zašumljenih podatkih z ij sidranjem. Prikazane so natančnosti napovedi elastičnih konstant iz zašumljenih ter nezašumljenih testnih podatkov.



Slika 12: Napoved elastične konstante iz eksperimentalnih podatkov. Za napoved sta bila uporabljena modela model0-ph ter model100-ph. Z vertikalnimi črtami so prikazana povprečja porazdelitev. Z rdečo barvo sta prikazani realni vrednosti elastičnih konstant.



Slika 13: Napoved elastične konstante iz eksperimentalnih podatkov. Za napoved je bilo uporabljenih pet modelov vsakega tipa (0 ter 100). Z vertikalnimi črtami so prikazana povprečja porazdelitev. Z rdečo barvo sta prikazani realni vrednosti elastičnih konstant.

4 Zaključek

V nalogi smo uporabljali nevronske mreže za napoved ene oz. dveh elastičnih konstant tekočih kristalov. Simulirali smo intenziteto žarka, ki prepotuje tekoč kristal, z znanima elastičnima konstantama, v katerem se direktorsko polje relaksira. Z velikim številom teh simulacij smo si pripravili učno množico za naše nevronske mreže. Med treningom smo na vходу mreže podali simulirano intenziteto v odvisnosti od časa za izhod smo pa popravljali z znanimi elastičnimi konstantami. Posikali smo optimalne hiperparametre za mrežo ter testirali kvaliteto napovedi. Na koncu smo elastični konstanti poskušali napovedati iz eksperimentalnih podatkov a smo žal dobili premajhne vrednosti. Sklepam, da zaradi fizikalnih procesov, ki v simulaciji niso upoštevani.